Hva tror en språkmodell om historiske personaer?

Sluttrapport av prosjektet i INF161

Eirik Aarrestad

Innholdsfortegnelse

1 Innledning **2**

2 Data og metode **3**
2.1 Datavalidering . . . 3
2.2 Manglende data . . . 3
2.3 Trenings-, valideringss- og testsplitt . . . 5
2.4 Variabelutvinning og manglende data i modellene . . . 5
2.5 Pipeline . . . 6
2.6 Ytelsesmål . . . 6
2.7 Reproduserbarhet . . . 7

3 Del 1: Hva fant vi i dataene? **7**
3.1 Statistisk beskrivelse . . . 7
3.2 Sammenhenger mellom svarene . . . 9
3.3 Hva tror språkmodellen om historien? . . . 10
3.4 Yrke, livstilfredshet og politikk . . . 10
3.5 Ekte og fiktive personaer . . . 11

4 Del 2: Prediktive modeller **12**
4.1 Modeller og modellvalg . . . 12
4.2 Oppgave A: når levde personen? . . . 13
4.2.1 Sammenligning av modellene . . . 13
4.2.2 Hvilke svar avslører epoken? . . . 15
4.2.3 Endelig modell på testsettet . . . 15
4.3 Oppgave B: hva drev personen med? . . . 17
4.3.1 Hvor ligger informasjonen? . . . 17
4.3.2 Sammenligning av modellene . . . 17

4.3.3 Endelig modell på testsettet 20

5 Diskusjon av resultatene **21**
5.1 Hvordan analyserte vi resultatene? 21
5.2 Er resultatene overraskende? 22
5.3 Er resultatene tilfredsstillende, og kan modellene brukes? 22
5.4 Tilnærminger som ikke ble brukt i den endelige modellen 23

6 Hva gikk galt? **23**

7 Hva ville vi gjort med mer tid? **23**

8 Konklusjon **24**

9 Bruk av KI **25**

1 Innledning

Datasettet `persona_survey.csv` består av 10 000 kjente personer og figurer: 9 000 ekte personer fra Pantheon-databasen og 1 000 fiktive figurer. En språkmodell har svart på 62 spørsmål som om den var hver av dem. Spørsmålene dekker personlighet (Big Five), politiske holdninger (politisk kompass), moral og tro, personlige preferanser og «moralske vekslingskurser». Datasettet inneholder også fasit om personene, blant annet yrke, kjønn og fødselsår.

Et viktig utgangspunkt er at svarene ikke er personenes egne. De er språkmodellens forestilling om hvordan personen ville svart. Når vi finner et mønster, sier det derfor noe om hva språkmodellen tror om historien, ikke om de historiske personene selv.

Prosjektet har tre deler, og denne rapporten forteller hele historien:

- **Del 1 – utforskende dataanalyse:** hvordan dataene ser ut, og hvilke mønstre språkmodellen har.
- **Del 2 – prediktiv modellering:** kan vi, bare ut fra svarene, predikere når en person levde (oppgave A, regresjon på `born`) og hva personen drev med (oppgave B, klassifikasjon av `occupation_category`)?
- **Del 3 – en sammenhengende pipeline:** alt ligger i notebooken `del3_final.ipynb`, som kjører fra innlesing av rådata til endelige skårer og figurer.

Til slutt diskuterer vi hva som gikk galt, og hva vi ville gjort med en uke til.

Hovedresultater. Datasettet er delt 70/15/15 i trening, validering og test (stratifisert på yrkeskategori). Modellene er valgt på valideringssettet, og tallene under er fra testsettet, som bare er brukt en gang per oppgave.

Tabell 1: Valgte modeller og ytelse på testsettet.

oppgave	valgt modell	mål (testsettet)	baseline (testsettet)
A: fødselsår (regresjon)	Random Forest på alle svar, tekst via TF-IDF (300 vanligste ord)	**MAE 285 år**, medianfeil 94 år	MAE 452 år, medianfeil 90 år
B: yrkeskategori (10 klasser)	logistisk regresjon ($C = 1$) på alle svar, tekst via TF-IDF	**balanced accuracy 0,692**, makro-F1 0,662	balanced accuracy 0,100

2 Data og metode

2.1 Datavalidering

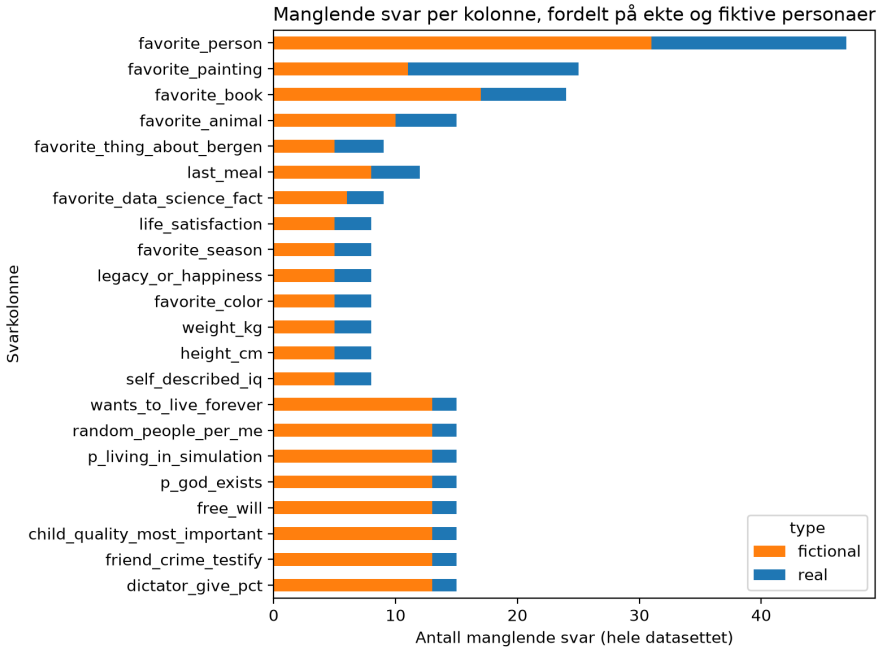
Datasettet har 10 000 rader og 74 kolonner, ingen dupliserte rader og en unik `persona_id` per rad. 24 navn brukes av mer enn en persona, så vi kobler aldri på `name`. Vi sjekket at hver svarkolonne har riktig datatype, og at alle svar ligger innenfor de lovlige verdiene i datakatalogen (skala 1–5 for Big Five, 0–100 for sannsynligheter, IQ 40–250, faste kategorier osv.). Vi sammenlignet minste og største verdi for de numeriske spørsmålene og svaralternativene i de kategoriske med katalogen. Ingen svar har ugyldige verdier.

Noen svar er likevel urealistiske: høyde fra 1 til 500 cm, vekt opp til 2000 kg og vekslingskurser opp til 10^9. 86 av de 88 ekstreme høyde- og vektsvarene tilhører fiktive figurer som Hulk og Loch Ness-monsteret, der svaret gir mening innenfor fiksjonen. De to ekte er Robert Wadlow (272 cm, verdens høyeste menneske) og en bjørn. Vi beholder derfor verdiene og bruker heller metoder som tåler dem: $\log_{10}$-transformasjon og trebaserte modeller.

2.2 Manglende data

Under 0,5 % av svarene mangler i hver kolonne (Figure 1). Big Five, politisk kompass og vekslingskursene mangler aldri. Svarene mangler seksjonsvis: når språkmodellen ikke ga et gyldig svar for en hel seksjon, mangler alle kolonnene der (`values` for 15 personaer, de faste `personal`-spørsmålene for 8), noe `sections_ok` bekrefter. I tillegg mangler enkelte fritekstsvar, opp til 47 for `favorite_person`.

Det mangler ikke helt tilfeldig. Fiktive figurer er bare 10 % av datasettet, men står for de fleste manglende svarene (13 av 15 i `values`). Språkmodellen klarer eller vil altså ikke alltid svare som enkelte figurer. Fasitkolonnen `born` mangler for 35 fiktive figurer, og `died` for 2230 personer (alle som lever, er udødelige eller aldersløse).



Figur 1: Antall manglende svar per svarkolonne i hele datasettet, fordelt på ekte (blå) og fiktive (oransje) personaer. Bare kolonner med minst ett manglende svar vises. Fiktive figurer står for de fleste manglende svarene, selv om de bare er 10 % av datasettet.

2.3 Trenings-, valideringss- og testsplitt

Rett etter valideringen delte vi datasettet 70/15/15 i trening (7000), validering (1500) og test (1500), stratifisert på `occupation_category` med fast tilfeldighetsfrø (`random_state=42`). Vi stratifiserer fordi yrkeskategoriene er svært ubalanserte (fra 373 til 3542 personer), og en tilfeldig splitt kunne gitt for få av de minste klassene i valideringss- eller testsettet. Manglende yrkeskategori ble behandlet som en egen gruppe i stratifiseringen. Andelen fiktive personaer (ca. 10 %) ble bevart i alle tre settene uten at vi stratifiserte på den.

All utforskende analyse etter splitten er gjort bare på treningssettet. Alle modeller er tilpasset på treningssettet, alle valg er gjort på valideringssettet, og testsettet er brukt en gang per oppgave, på den valgte modellen.

2.4 Variabelutvinning og manglende data i modellene

Begge oppgavene bruker bare de 62 svarkolonnene som input. Fasitkolonner som `died`, `occupation`, `name`, `type` og `gender` gir enten svaret direkte eller er ikke en del av undersøkelsen, så de brukes ikke. `type` brukes bare i etterkant til å analysere feilene. Fra svarene lager vi nye variabler (Table 2).

Tabell 2: Variabler laget fra de 62 svarkolonnene.

variabel	hvordan	hvorfor
5 Big Five-skårer	reverserte ledd snus med $6 - x$, snittet av leddene $\times 4$ (4–20)	datakatalogens skåring. Et manglende ledd trekker ikke skåren ned
2 politiske akser	svarene kodes $-2, -1, +1, +2$ og summeres per akse (-12 til 12)	datakatalogens skåring
9 log-variabler	$\log_{10}$ av vekslingskursene og `random_people_per_me`	spenner fra 10^{-12} til 10^{9}
7 ordtellinger	antall ord i hvert fritekstsvar	lengden på svaret kan si noe om rollen
`n_missing`	antall manglende svar for personaen	manglende svar er ikke tilfeldige
`all_text`	de sju fritekstsvarene slått sammen	en TF-IDF-modell for all tekst
32 enkeltledd (valgfritt)	Big Five-leddene og de politiske utsagnene som tall	testes på valideringssettet

Strategien for manglende data er tilpasset variabeltypen (Table 3).

Tabell 3: Strategi for manglende data per variabeltype.

variabeltype	strategi	begrunnelse
numerisk	median fra treningsdata	robust mot skjeve fordelinger, gjelder under 0,5 %
kategorisk	egen kategori `"missing"`	at modellen ikke svarte, er informativt
fritekst	tom tekst	gir ingen ord til TF-IDF, i stedet for å finne på et svar
Big Five / politisk	snitt av besvarte ledd / 0 (nøytral)	mangler aldri her, men gjør pipelinen robust
målvariabelen	raden fjernes i den oppgaven	kan verken trenes eller evalueres uten fasit

2.5 Pipeline

All forbehandling ligger inne i en scikit-learn-`Pipeline`, bygget av en hjelpefunksjon som brukes i begge oppgavene:

1. `FunctionTransformer(add_features)` lager variablene i Table 2. Den jobber rad for rad og lærer ingenting fra dataene, så den kan ikke lekke informasjon.
2. `ColumnTransformer` behandler gruppene hver for seg: median-imputering og `StandardScaler` for tall, `OneHotEncoder` for kategorier og `TfidfVectorizer` (engelske stoppord fjernet, ord som finnes i minst to svar) for tekst. For Random Forest beholder TF-IDF bare de 300 eller 1000 vanligste ordene, fordi trær blir trege og finner sjelden de nyttige ordene blant tusenvis av glisne ordkolonner.
3. **Modellen.**

Imputering, skalering og TF-IDF-vokabular læres derfor bare fra dataene modellen trenes på, og den samme pipelinen brukes uendret på validerings- og testdata.

2.6 Ytelsesmål

Oppgave A. Vi bruker MAE (mean absolute error) i år som hovedmål, fordi det er lett å tolke: «modellen bommer i snitt med X år». Fødselsårene spenner fra $-10\,000$ til $10\,190$, siden fiktive figurer kan oppgi hva som helst. RMSE ville latt noen få slike figurer dominere hele målet. I tillegg rapporterer vi medianfeil, som er enda mer robust.

Oppgave B. Klassene er svært ubalanserte, så vanlig accuracy ville belønnet en modell som nesten bare gjetter `politics & rule`. Vi bruker balanced accuracy, gjennomsnittet av recall

per klasse, som hovedmål. Da teller hver klasse like mye, og tilfeldig gjetting gir 0,10. Vi rapporterer også makro-F1, som i tillegg tar hensyn til precision.

2.7 Reproduserbarhet

Hele analysen ligger i `del3_final.ipynb`, som kjører fra topp til bunn uten manuelle steg. Alle tilfeldige steg (splitt, Random Forest, logistisk regresjon, gradient descent, kryssvalidering og permutasjonsviktighet) bruker `random_state=42`. Første kodecelle skriver ut versjonene av Python og bibliotekene, og de står også i `requirements.txt`. Tabellen med endelige resultater bygges fra variablene i koden, ikke skrevet inn for hånd. Notebooken er kjørt to ganger med identiske tall.

3 Del 1: Hva fant vi i dataene?

3.1 Statistisk beskrivelse

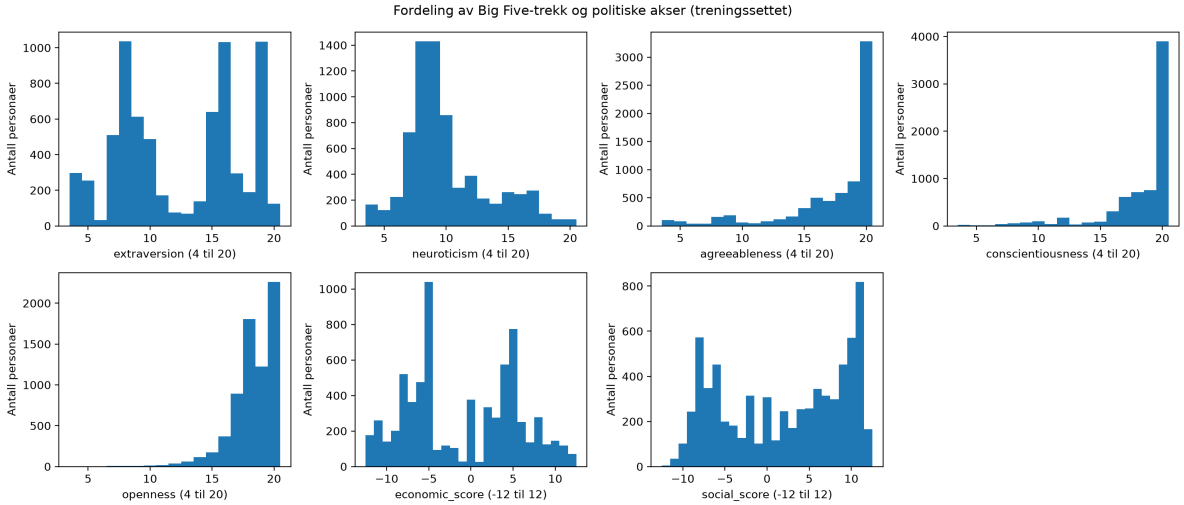
Notebooken (seksjon 3) har en fullstendig statistisk beskrivelse av alle 62 svarkolonnene og fasitkolonnene på treningssettet: fordelingsmål, manglende verdier og skjevhet for de 36 numeriske, antall kategorier og vanligste og sjeldneste kategori for de 19 kategoriske (inkludert politisk kompass), og antall unike svar, snittlengde og vanligste svar for de 7 fritekstene. Her trekker vi fram det viktigste.

Språkmodellen har et fast bilde av en «kjent person». Mange svar er svært ubalanserte: 93 % velger *a lasting legacy* framfor *a happy life*, gull er favorittfargen til 41 %, og to av tre foretrekker høsten. Medianen for selvrapportert IQ er 145. Det vanligste dyret er falken, og *The Art of War*, *The Starry Night* og Marcus Aurelius dukker opp hos svært mange.

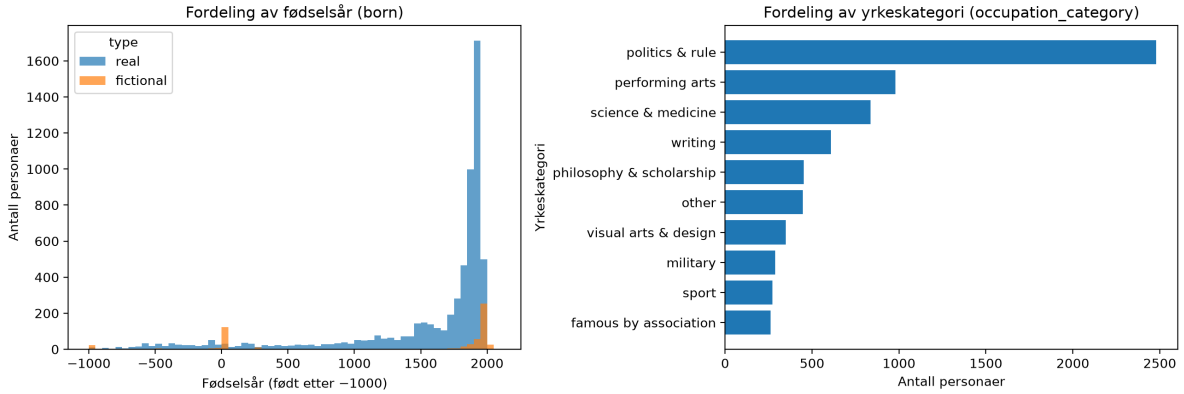
Personlighetsskårene er sterkt skjeve, se (Figure 2). Omgjengelighet, planmessighet og åpenhet ligger nesten alltid nær toppen av skalaen (median 18–20 av 20), og nevrotisisme er lav. Ekstroversjon er det eneste trekket som brukes over hele skalaen.

De numeriske svarene er skjeve og har ekstreme verdier. `p_living_in_simulation` er nesten alltid 0, mens vekslingskursene har skjevhet fra ca. 3 til over 30. Det er grunnen til at vi bruker $\log_{10}$, median-imputering og MAE.

Målvariablene er krevende (Figure 3). `born` er sterkt venstreskjev: de fleste er født etter 1800, men halen strekker seg til antikken, og noen få (for det meste fiktive) har år helt ned til $-10\,000$ og opp til 10 190. `occupation_category` er svært ubalansert: `politics & rule` er nesten ti ganger så stor som `famous by association`.



Figur 2: Fordeling av de fem Big Five-trekkene (4–20) og de to politiske aksene (−12 til 12; økonomisk: positiv = høyre, sosial: positiv = autoritær) på treningssettet.



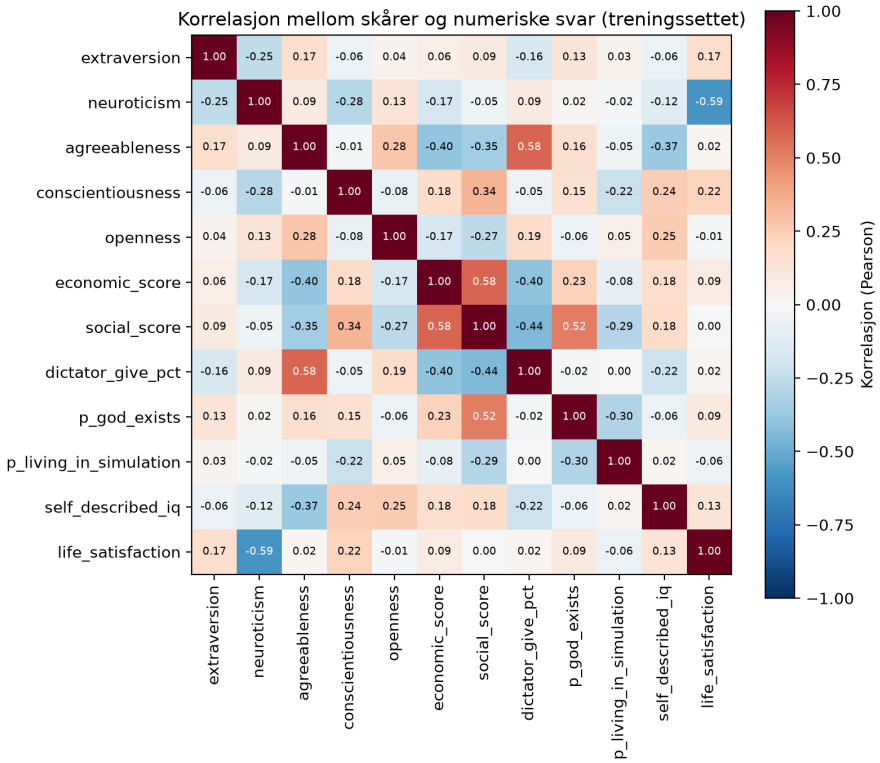
Figur 3: Fordeling av de to målvariablene på treningssettet. Venstre: fødselsår for personaer født mellom −1000 og 2100, fordelt på ekte og fiktive. Høyre: antall personaer per yrkeskategori.

3.2 Sammenhenger mellom svarene

Figure 4 viser korrelasjonen mellom skårene og de numeriske svarene. Høyde, vekt og vekslingskursene er utelatt, siden de ekstreme verdiene ville dominert korrelasjonen. Tre mønstre skiller seg ut:

- Den økonomiske og den sosiale aksen korrelerer (0,58), og den sosiale aksen henger sammen med tro på Gud (0,52). Språkmodellen plasserer altså personer langs en «konservativ–progressiv»-dimensjon mer enn i fire uavhengige kvadranter.
- Omgjengelighet og `dictator_give_pct` korrelerer (0,58): omgjengelige personaer gir mer til en fremmed.
- Nevrotisisme og livstilfredshet korrelerer negativt (−0,59), slik vi ville forventet hos ekte mennesker.

Svarene henger altså sammen på en psykologisk konsistent måte.



Figur 4: Korrelasjon (Pearson) mellom Big Five-skårene, de politiske aksene og de numeriske svarene på treningssettet. Rødt er positiv og blått negativ korrelasjon, og tallet i hver celle er korrelasjonen.

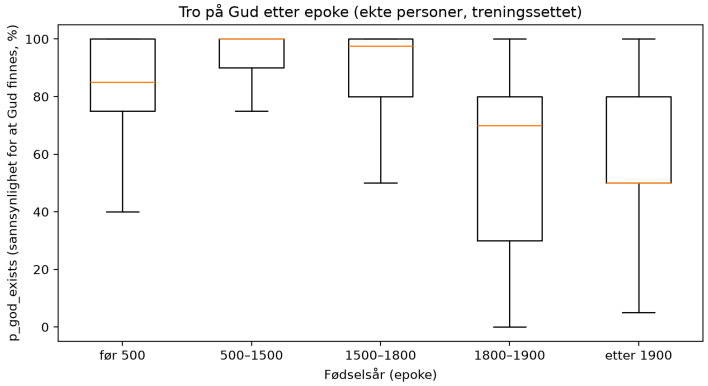
3.3 Hva tror språkmodellen om historien?

Vi delte de ekte personene i treningssettet inn i fem epoker etter fødselsår (Table 4). Fiktive figurer er utelatt, siden fødselsårene deres er vilkårlige.

Tabell 4: Gjennomsnittlige svar per epoke for ekte personer på treningssettet. Sosial akse: positiv = autoritær. Økonomisk akse: positiv = høyre.

epoke	tro på Gud (%)	sosial akse	økonomisk akse	simulering (%)	IQ
før 500	78,5	5,3	0,1	3,0	147,8
500–1500	91,4	7,2	−0,2	1,6	142,8
1500–1800	85,6	5,6	1,7	0,9	143,3
1800–1900	59,6	1,6	−0,9	2,0	141,2
etter 1900	56,9	−1,6	−2,7	5,8	134,6

Moderne personer fremstilles som mer liberale, mindre religiøse, mer åpne for simuleringshypotesen og mer beskjedne om egen intelligens. Figure 5 viser at sammenhengen ikke er lineær. Personer født 500–1800 tror nesten sikkert at Gud finnes (median 97,5–100 %), mens medianen faller til 70 % for 1800-tallet og 50 % etter 1900. Antikken ligger lavere enn middelalderen, trolig fordi mange antikke personer var polyteister eller filosofer. Mønsteret ser ut som et trinn rundt 1800. Det motiverte trebaserte modeller i oppgave A.



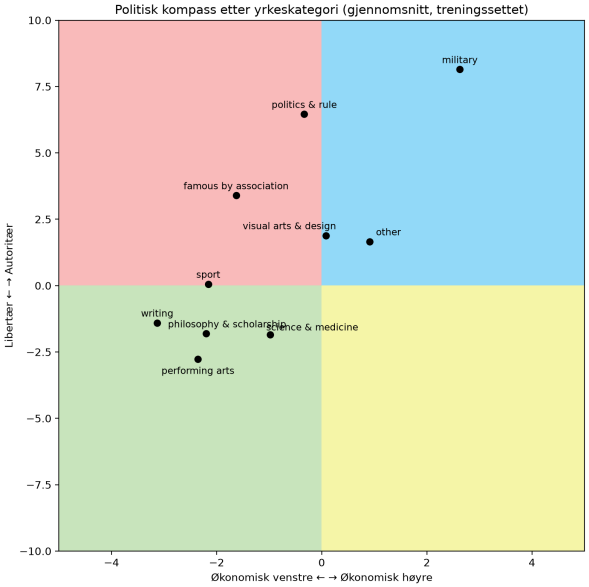
Figur 5: Sannsynlighet for at Gud finnes (`p_god_exists`) etter epoke, for ekte personer på treningssettet. Boksen viser kvartilene og streken medianen.

3.4 Yrke, livstilfredshet og politikk

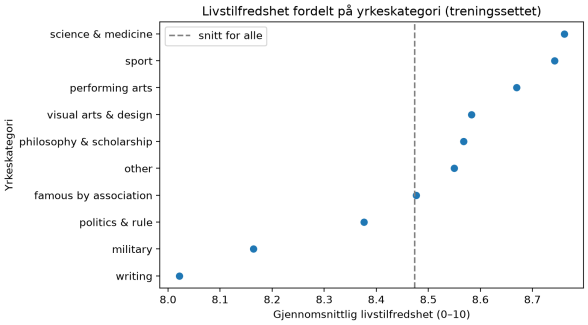
Det politiske kompasset skiller mellom yrker (Figure 6). `military` og `politics & rule` ligger tydelig på den autoritære siden, og `military` også til høyre. `writing`, `philosophy &`

`scholarship`, `science & medicine` og `performing arts` ligger på den liberale venstresiden. `visual arts & design` ligger overraskende nær midten. Svarene bærer altså informasjon om yrke, noe vi utnytter i oppgave B.

Livstilfredshet er høy for alle yrker (median 8–9 av 10), og forskjellene er små (Figure 7): `writing` og `military` ligger lavest, mens `science & medicine` og `sport` ligger høyest. Språkmodellen ser ut til å ha et bilde av den plagede forfatteren.



Figur 6: Gjennomsnittlig politisk plassering per yrkeskategori på treningssettet. Kvadrantene viser autoritær venstre (rød), autoritær høyre (blå), libertær venstre (grønn) og libertær høyre (gul).



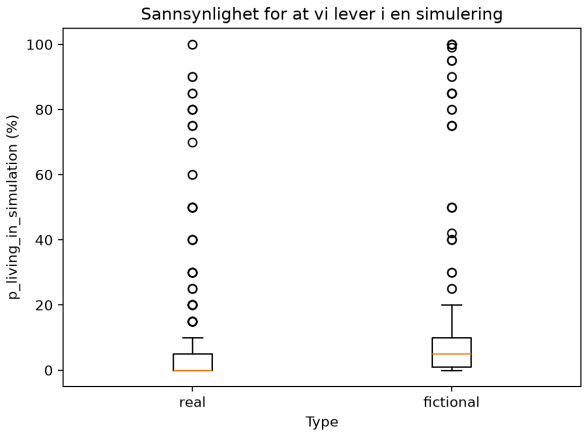
Figur 7: Gjennomsnittlig livstilfredshet (0–10) per yrkeskategori på treningssettet. Den stiplede linjen er snittet for alle.

3.5 Ekte og fiktive personaer

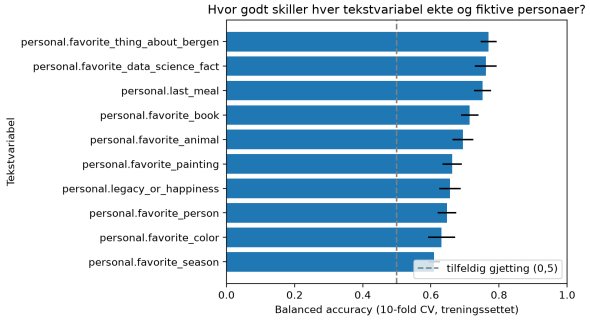
Fiktive personaer gir høyere sannsynlighet for at vi lever i en simulering enn ekte (snitt 11,4 % mot 3,2 %, median 5 % mot 0 %). En ensidig Welch's t-test (ulike varianser og gruppestørrelser) gir $t = 10{,}3$ og $p = 1{,}2 \cdot 10^{-23}$, så vi forkaster nullhypotesen om at fiktive ikke har høyere snitt. Fordelingen er svært skjev, men med 691 fiktive og 6299 ekte personaer er t-testen rimelig på grunn av sentralgrenseteoremet.

Også tekstsvarene skiller gruppene godt. Med TF-IDF og logistisk regresjon, evaluert med stratifisert 10-fold kryssvalidering på treningssettet, er de åpne setningsspørsmålene best:

`favorite_thing_about_bergen` (balanced accuracy 0,77) og `favorite_data_science_fact` (0,76). Der får språkmodellen mest rom til å spille rollen, og stilen avslører figuren. Ord som *dramatic*, *mist* og *vast* trekker mot fiktiv, mens *happy*, *life* og *odyssey* trekker mot ekte (notebook seksjon 6).



Figur 8: Sannsynlighet for at vi lever i en simulering (`p_living_in_simulation`) for ekte og fiktive personaer på treningssettet. Boksen viser kvartilene, streken medianen og sirklene uteliggere.



Figur 9: Balanced accuracy (snitt og standardavvik over 10-fold kryssvalidering på treningssettet) for TF-IDF + logistisk regresjon trent på en tekstvariabel om gangen for å skille ekte fra fiktive. Den stiplede linjen er tilfeldig gjetting (0,5).

Figure 8 viser at forskjellen i simuleringstro skyldes at fiktive personaer sjeldnere svarer 0, og Figure 9 at alle tekstvariablene skiller gruppene bedre enn tilfeldig, mest de åpne setningsspørsmålene.

4 Del 2: Prediktive modeller

4.1 Modeller og modellvalg

Alle modeller sammenlignes med en baseline: medianen av fødselsår i oppgave A og den største klassen i oppgave B. Vi går fra enkle til mer komplekse modeller:

- **Lineære modeller:** lineær regresjon i oppgave A og logistisk regresjon (tuning av regulariseringen C) i oppgave B. Logistisk regresjon passer godt til tusenvis av TF-IDF-variabler, og koeffisientene er lett tolkbare.
- **Lineære modeller tilpasset med stokastisk gradient descent** (`SGDRegressor` og `SGDClassifier`). Modellen oppdateres med små steg mot den negative gradienten av

tapet, ett datapunkt om gangen, og har en L2-straff $\alpha \sum \beta_j^2$ som vi tuner. Fordelen er at vi kan velge tapsfunksjonen selv. I oppgave A bruker vi absoluttfeil $|y - \hat{y}|$ (`loss="epsilon_insensitive"` med `epsilon=0`), altså det samme som ytelsesmålet MAE. Vanlig lineær regresjon minimerer kvadratfeil og blir dratt mot de ekstreme fødselsårene. Fødselsåret standardiseres under treningen, slik at gradientstegene får en fornuftig størrelse. I oppgave B bruker vi log-tap, altså den samme modellen som logistisk regresjon, men tilpasset med SGD i stedet for L-BFGS.

- **Random Forest:** fanger ikke-lineære sammenhenger og samspill, som trinnet rundt 1800 i Figure 5. Vi tuner `max_depth` og `min_samples_leaf`, som styrer hvor komplekse trærne blir.

I oppgave B bruker alle modellene `class_weight="balanced"`, som vekter sjeldne klasser opp under treningen.

Variabelutvalg gjøres på gruppenivå. Vi sammenligner på valideringssettet om det hjelper å legge til (1) tekst og (2) de 32 enkeltleddene utover de summerte skårene, og for Random Forest hvor mange ord TF-IDF skal beholde (300 eller 1000). Modellutvalg gjøres på valideringssettet: modellen med best hovedmål velges, trenes på nytt på trening + validering og evalueres en gang på testsettet.

Ett valideringssett på ca. 1500 personer gir usikre tall, og i del 2 falt resultatet i oppgave B tydelig fra validering til test. Som en robusthetssjekk kjører vi derfor 5-fold kryssvalidering på treningssettet for de tre beste modellene. CV brukes ikke til å velge modell, men til å vurdere om forskjellene mellom modellene er større enn støyen.

4.2 Oppgave A: når levde personen?

4.2.1 Sammenligning av modellene

Tabell 5: Utvalgte resultater på valideringssettet for oppgave A. Alle resultatene står i notebooken (seksjon 10.2).

modell	MAE (år)	medianfeil (år)
Baseline (median)	504	**90**
Lineær regresjon: num + kat	509	304
SGD (absoluttfeil): num + kat	438	128
SGD (absoluttfeil): alle svar (α = 0,0001 / 0,001 / 0,01)	358 / 358 / 383	109 / 106 / 106
Random Forest: num + kat (dybde 10 / 20 / ubegrenset, beste leaf)	393 / 373 / 373	154 / 149 / 148

modell	MAE (år)	medianfeil (år)
Random Forest: num + kat + enkeltledd	371	147
Random Forest: alle svar (300 ord)	**304**	109
Random Forest: alle svar (1000 ord)	309	106

Table 5 og Figure 10 viser fire tydelige mønstre:

- **Lineær regresjon uten tekst er ikke bedre enn baseline** (509 mot 504 år). Sammenhengen mellom svarene og fødselsår er ikke lineær, og kvadratfeilen lar de ekstreme fødselsårene trekke modellen.
- **Tapsfunksjonen betyr mye.** Den samme lineære modellen tilpasset med gradient descent på absoluttfeil får 438 år i stedet for 509, og medianfeilen faller fra 304 til 128 år. Med tekst får den 358 år. $\alpha = 0{,}01$ regulariserer for mye.
- **Teksten er den viktigste variabelgruppen.** Å legge til de 300 vanligste ordene gir Random Forest 69 år lavere MAE (373 → 304). Enkeltleddene gir nesten ingenting utover de summerte skårene, og 1000 ord er ikke bedre enn 300.
- **Random Forest:** dybde 10 er for grunt (undertilpasning). Fra dybde 20 er resultatene nesten like, og `min_samples_leaf=3` er best.

Ingen modell slår baseline på medianfeil. Halvparten av personene er født mellom 1434 og 1927, og medianen (1858) treffer den store gruppen moderne personer godt. Modellene bytter litt større feil på moderne personer mot mye mindre feil på eldre. Siden målet er å si noe om når *alle* personer levde, velger vi etter MAE.

Kryssvalidering på treningssettet bekrefter at Random Forest med tekst er best (Table 6), 32–35 år bedre enn SGD, som er omtrent to standardavvik over foldene. Forskjellen mellom 300 og 1000 ord er derimot bare 3–5 år og bytter fortegn mellom validering og CV, altså støy. Valget følger regelen (valideringssettet): Random Forest på alle svar med de 300 vanligste ordene (`max_depth=None`, `min_samples_leaf=3`).

Tabell 6: Robusthetssjekk for de tre beste modellene i oppgave A: valideringssettet mot 5-fold kryssvalidering på treningssettet.

modell	MAE (validering)	MAE (5-fold CV)	std over fold
Random Forest: alle svar (300 ord)	304,1	316,3	12,6
Random Forest: alle svar (1000 ord)	308,8	313,4	15,4

modell	MAE (validering)	MAE (5-fold CV)	std over fold
SGD (absoluttfeil): alle svar ($\alpha = 0{,}0001$)	357,7	348,4	17,6

4.2.2 Hvilke svar avslører epoken?

Vi målte permutasjonsviktighet på valideringssettet, med modellen trent bare på treningssettet: hvor mye øker MAE når vi stokker ett av de 62 svarene? Siden pipelinen tar rådata som input, måler vi viktigheten av hvert spørsmål.

Figure 11 viser at `last_meal` er klart viktigst: å stokke det øker MAE med over 200 år. Språkmodellen lar altså historiske personer velge mat fra sin egen tid og kultur. Deretter kommer favorittbok, selvrapportert IQ (som vi i del 1 så faller for moderne personer), favorittmaleri og data science-svaret. Personlighet og politikk betyr lite når teksten er med, selv om de henger sammen med fødselsår. Trolig fanger teksten opp den samme informasjonen mer presist.

4.2.3 Endelig modell på testsettet

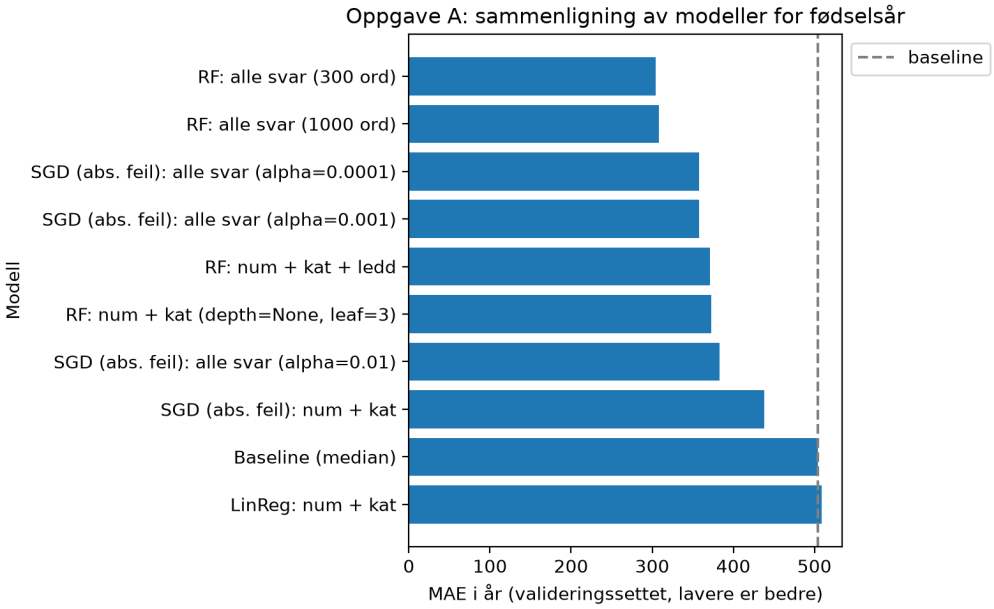
Den valgte modellen får **MAE = 285,2 år** og **medianfeil = 94,2 år** på testsettet, mot 452,2 og 90,0 år for baseline. Det er en klar forbedring fra del 2 (MAE 363,6 år på det samme testsettet), men medianfeilen er fortsatt litt dårligere enn baseline. Testresultatet er litt bedre enn valideringsresultatet (304 år), innenfor variasjonen vi så i kryssvalideringen.

Tabell 7: Absolutt feil på testsettet fordelt på type og epoke. `type` og `born` brukes bare til analyse, ikke som input.

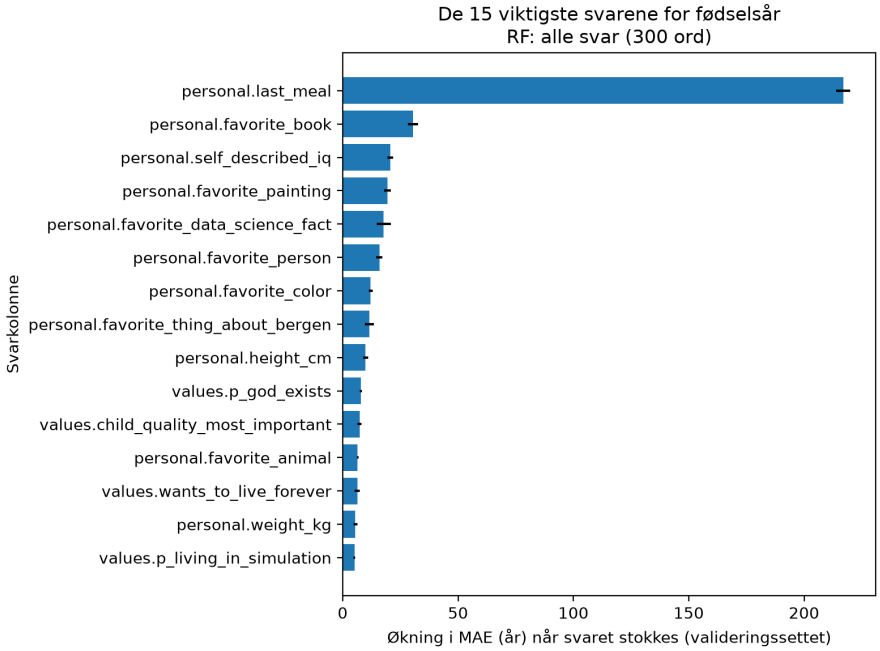
gruppe	antall	gj.snittlig feil (år)	medianfeil (år)
fiktive	156	929	579
ekte	1338	210	79
ekte, født før 500	139	650	416
ekte, født 500–1500	212	315	229
ekte, født 1500–1800	202	159	94
ekte, født 1800–1900	335	123	41
ekte, født etter 1900	450	113	44

Figure 12 og Table 7 viser hvor modellen feiler:

- **Fiktive figurer har over fire ganger så stor feil.** Fødselsårene deres er ofte vilkårlige, og svarene speiler universet de hører til, ikke en historisk epoke. Det gir den loddrette stripen rundt år 0: mytologiske og bibelske figurer predikeres som moderne.

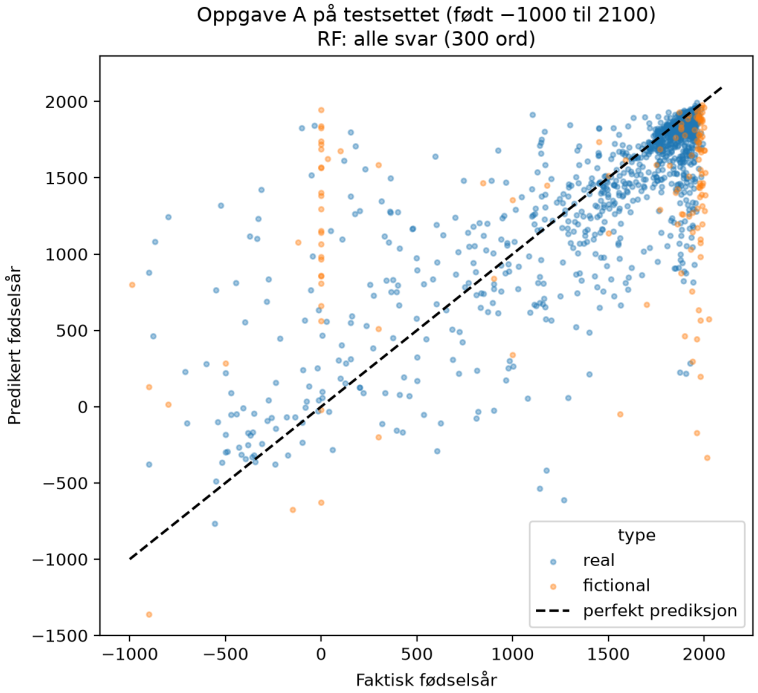


Figur 10: MAE på valideringssettet for modellene i oppgave A (for Random Forest-gridet vises bare den beste kombinasjonen). Den stiplede linjen er baseline. Lavere er bedre.



Figur 11: Permutasjonsviktighet for de 15 viktigste svarene i den valgte modellen for oppgave A: økning i MAE (år) på valideringssettet når svaret stokkes, snitt over 5 gjentakelser med standardavvik.

- **Feilen øker kraftig bakover i tid**, fra en median på 41–44 år for personer født etter 1800 til over 400 år for antikken. Prediksjonene presses mot midten (*regression to the mean*), fordi det er få gamle personer å lære av.



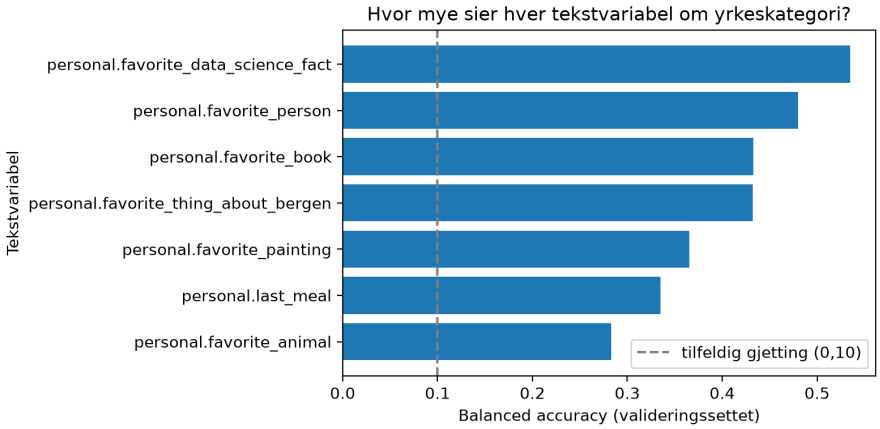
Figur 12: Predikert mot faktisk fødselsår på testsettet for den valgte modellen, for personaer født mellom −1000 og 2100. Blå punkter er ekte og oransje fiktive personaer. Den stiplede linjen er perfekt prediksjon. Y-aksen er begrenset til −1500–2300, så noen få ekstreme prediksjoner faller utenfor.

4.3 Oppgave B: hva drev personen med?

4.3.1 Hvor ligger informasjonen?

Som i del 1 trente vi først TF-IDF og logistisk regresjon på en tekstvariabel om gangen (Figure 13). `favorite_data_science_fact` (0,54) og `favorite_person` (0,48) sier mest om yrke, og `favorite_animal` (0,28) minst. At «tullespørsmålet» om data science er best, viser at språkmodellen formulerer svaret i stil med personens fag: en fysiker nevner naturlover, en general strategi.

4.3.2 Sammenligning av modellene



Figur 13: Balanced accuracy på valideringssettet for TF-IDF + logistisk regresjon trent på en tekstvariabel om gangen. Den stiplede linjen er tilfeldig gjetting (0,10).

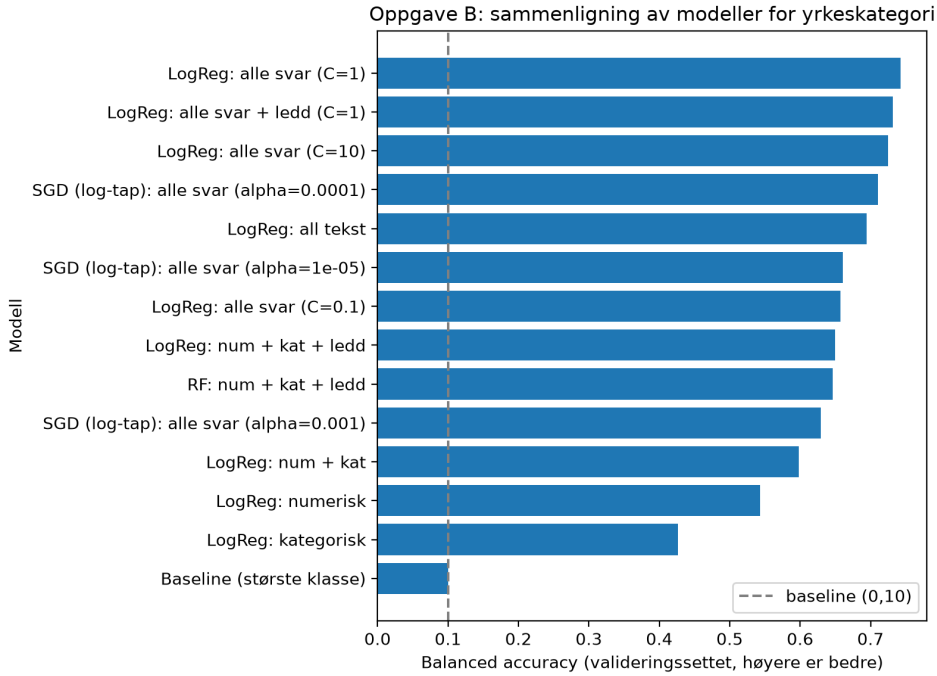
Tabell 8: Utvalgte resultater på valideringssettet for oppgave B. Alle 14 modellene står i notebooken (seksjon 11.2).

modell	balanced accuracy	makro-F1
Baseline (største klasse)	0,100	0,052
LogReg: num + kat	0,598	0,538
LogReg: num + kat + enkeltledd	0,650	0,597
Random Forest: num + kat + enkeltledd	0,646	0,602
LogReg: all tekst	0,694	0,652
LogReg: alle svar ($C = 0{,}1$ / **1** / 10)	0,657 / **0,743** / 0,724	0,601 / 0,703 / **0,707**
LogReg: alle svar + enkeltledd ($C = 1$)	0,731	0,699
SGD (log-tap): alle svar (α = 0,00001 / 0,0001 / 0,001)	0,648 / 0,713 / 0,630	0,647 / 0,685 / 0,614

Table 8 og Figure 14 viser:

- Uten tekst hjelper enkeltleddene for logistisk regresjon (0,598 → 0,650), og Random Forest er omtrent like god (0,646).
- Tekst alene (0,694) er bedre enn alle de andre svarene til sammen, og å kombinere alt gir best resultat (0,743).
- Regularisering $C = 0{,}1$ gir for enkel modell, $C = 1$ er best, og $C = 10$ er litt dårligere.

- Gradient descent gir 0,713 med best α, litt dårligere enn den samme modellen tilpasset med L-BFGS (0,743). SGD tar mange støyete steg og ender ikke helt optimalt, og den er følsom for α: for liten straff overtilpasser og for stor undertilpasser.
- Med tekst hjelper ikke enkeltleddene lenger (0,731 mot 0,743).



Figur 14: Balanced accuracy på valideringssettet for alle modellene i oppgave B. Den stiplede linjen er baseline (0,10). Høyere er bedre.

Kryssvalideringen nyanserer bildet (Table 9). Valideringsvinneren, logistisk regresjon på alle svar med $C = 1$, er ikke best i CV: modellen med enkeltledd får 0,710 mot 0,693, og valideringstallet ligger 0,05 over CV-snittet. Det er et typisk eksempel på *winner's curse*: når vi velger den beste av 14 kandidater på ett valideringssett, velger vi delvis den som var heldig. Forskjellen er likevel bare omtrent ett standardavvik over foldene.

Tabell 9: Robusthetssjekk for de tre beste modellene i oppgave B: valideringssettet mot stratifisert 5-fold kryssvalidering på treningssettet.

modell	bal.acc (validering)	bal.acc (5-fold CV)	std over fold
LogReg: alle svar ($C = 1$)	0,743	0,693	0,015
LogReg: alle svar + enkeltledd ($C = 1$)	0,731	0,710	0,011
LogReg: alle svar ($C = 10$)	0,724	0,688	0,015

Vi fulgte likevel den forhåndsbestemte regelen og valgte på valideringssettet. Å bytte modell

etter å ha sett CV-tallene ville vært et nytt modellvalg uten et urørt sett å evaluere det på. Dette diskuterer vi i Section 6.

4.3.3 Endelig modell på testsettet

Den valgte modellen, logistisk regresjon på alle svar med $C = 1$, får **balanced accuracy = 0,692** og **makro-F1 = 0,662** på testsettet (vanlig accuracy 0,735, baseline 0,10). Testtallet er nesten nøyaktig CV-snittet (0,693) og klart lavere enn valideringstallet (0,743). Kryssvalideringen ga altså et bedre anslag på generaliseringsevnen enn ett valideringssett.

Tabell 10: Resultater per klasse på testsettet for den valgte modellen i oppgave B, sortert etter recall.

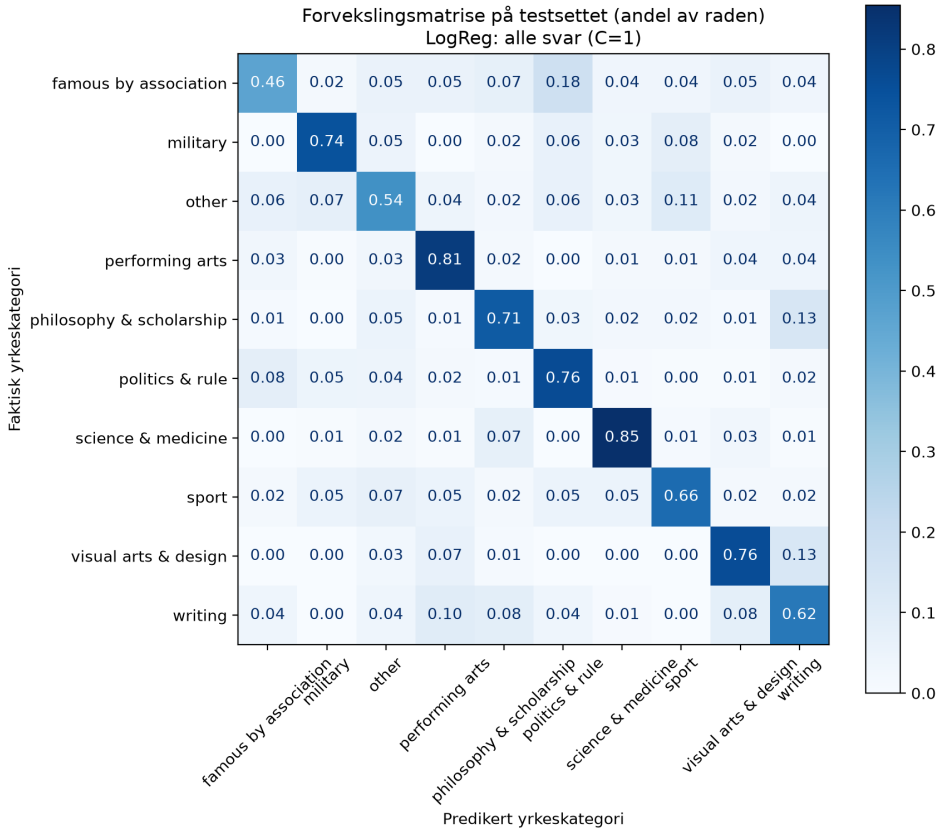
klasse	precision	recall	F1	antall
science & medicine	0,88	0,85	0,87	179
performing arts	0,81	0,81	0,81	210
politics & rule	0,93	0,76	0,84	531
visual arts & design	0,63	0,76	0,69	75
military	0,55	0,74	0,63	62
philosophy & scholarship	0,61	0,71	0,66	97
sport	0,60	0,66	0,63	59
writing	0,62	0,62	0,62	130
other	0,49	0,54	0,51	95
famous by association	0,30	0,46	0,36	56

Table 10 viser at `science & medicine`, `performing arts` og `politics & rule` både er lette å finne og sjelden feilpredikert. Det er store klasser med et tydelig ordforråd. `military` og `visual arts & design` har høy recall, men lav precision. Det er en direkte følge av `class_weight="balanced"`, som gjør at små klasser predikeres oftere, mens `politics & rule` får svært høy precision (0,93) og lavere recall. Sekkekategoriene `other` og `famous by association` er vanskeligst, siden de mangler et felles tema.

Forvekslingsmatrisen (Figure 15) viser at feilene følger meningsfulle grenser:

- **`famous by association` → `politics & rule` (18 %)** er den vanligste feilen. Mange som er kjent gjennom andre, er kongelige eller ektefeller til statsledere.
- **Kulturyrkene glir over i hverandre:** `philosophy & scholarship` → `writing` (13 %), `visual arts & design` → `writing` (13 %) og `writing` → `performing arts` (10 %).
- **`other` → `sport` (11 %)**: `other` inneholder trolig mange med fysiske eller underholdningsrettede yrker.

Koeffisientene viser hvilke ord modellen forbinder med hvert yrke (notebook seksjon 11.6): *enemy, war, strategic* for `military`, *melody, music, Beethoven* for `performing arts`, *biological, chemical, Principia* for `science & medicine`, og *prince, coronation* for `politics & rule`.



Figur 15: Normalisert forvekslingsmatrise på testsettet for den valgte modellen i oppgave B. Hver rad viser hvordan personene i en faktisk klasse fordeles på de predikerte klassene, så diagonalen er recall per klasse.

5 Diskusjon av resultatene

5.1 Hvordan analyserte vi resultatene?

Vi sammenlignet alltid med en baseline, slik at tallene har et referansepunkt. Vi brukte kryssvalidering for å vurdere om forskjellene mellom modellene er større enn støyen, siden ett valideringssett på 1500 personer er lite. For å forstå *hva* modellene bruker, målte vi permutasjonsviktighet (oppgave A) og så på koeffisientene (oppgave B). For å forstå *hvor* de feiler, delte vi feilene opp etter ekte og fiktive personer og etter epoke (oppgave A), og per

klasse og med forvekslingsmatrise (oppgave B). Det siste er viktig fordi ett samlet tall som MAE skjuler at feilen er svært ulik for ulike grupper.

5.2 Er resultatene overraskende?

Delvis. Ut fra del 1 forventet vi at svarene bærer mye informasjon. Språkmodellen har sterke og stereotype bilder av både epoker og yrker, så at begge modellene slår baseline klart, er ikke overraskende. Det samme gjelder at fritekst er viktigst: der kan språkmodellen nevne konkrete personer, bøker og malerier som hører til en tid eller et fag.

Det som overrasket oss, var:

- **`last_meal` er det klart viktigste svaret for fødselsår**, viktigere enn tro, politikk og personlighet. Mat viser seg å være en sterk tidsmarkør i språkmodellens rollespill.
- **«Tullespørsmålet» `favorite_data_science_fact` er det beste enkeltsvaret for yrke.** Språkmodellen skriver svaret i stil med personens fag.
- **Hvor mye tapsfunksjonen betydde i oppgave A.** Bare ved å bytte fra kvadratfeil til absoluttfeil, med den samme lineære modellen tilpasset med gradient descent, falt MAE fra 509 til 438 år og medianfeilen fra 304 til 128 år.
- **At ingen modell slo baseline på medianfeil.** En konstant gjetning på 1858 er vanskelig å slå for den store gruppen moderne personer.
- **At valideringsvinneren i oppgave B ikke var best i kryssvalidering.** Vi visste at ett valideringssett gir usikre tall, men ikke at det kunne snu rekkefølgen.

5.3 Er resultatene tilfredsstillende, og kan modellene brukes?

Begge modellene er klart bedre enn baseline på hovedmålet: MAE er 37 % lavere i oppgave A, og balanced accuracy er nesten sju ganger baseline i oppgave B. Modellene er gode for ekte personer fra de siste 200 årene (medianfeil 41–44 år) og for yrker med et tydelig ordforråd (`science & medicine`, `performing arts` og `politics & rule`, F1 over 0,8). De sliter med fiktive figurer, antikken og sekkekategoriene, fordi svarene der ikke peker mot en bestemt epoke eller ett fag.

Modellene predikerer hva denne språkmodellen tror, ikke egenskaper ved virkelige personer. Å bruke dem til å anslå når en ukjent person levde eller hva vedkommende drev med, ville derfor ikke gi mening. En realistisk bruk er å undersøke språkmodeller: hvor stereotypt en språkmodell spiller historiske roller, eller om et rollespill «avslører» feil epoke eller yrke. Det forutsetter at det er den samme språkmodellen og de samme spørsmålene, og at personene er ekte og fra omtrent etter 1500. Selv da gir oppgave A bare et grovt anslag.

5.4 Tilnærminger som ikke ble brukt i den endelige modellen

- **Lineær regresjon** (oppgave A) var ikke bedre enn baseline, fordi sammenhengen mellom svar og fødselsår er ikke-lineær (et trinn rundt 1800), og fordi kvadratfeil lar de ekstreme fødselsårene trekke modellen.
- **SGD med absoluttfeil** (oppgave A) var mye bedre enn lineær regresjon, men en lineær modell fanger ikke trinnet rundt 1800 like godt som Random Forest.
- **Enkeltleddene** fra Big Five og det politiske kompasset hjalp uten tekst, men ikke når teksten var med. Informasjonen overlapper med skårene og teksten.
- **SGD med log-tap** (oppgave B) var 0,03 dårligere enn logistisk regresjon tilpasset med L-BFGS. SGD ender ikke helt i optimum og er følsom for α.
- **For sterk eller for svak regularisering** ($C = 0{,}1$ og $C = 10$, $\alpha = 0{,}01$ i oppgave A og $\alpha = 0{,}00001$ og $0{,}001$ i oppgave B) ga henholdsvis under- og overtilpasning.

6 Hva gikk galt?

- **Ett valideringssett var for støyete til å skille de beste modellene.** I oppgave B var valideringsvinneren ikke best i kryssvalidering, og testresultatet (0,692) traff CV-anslaget, ikke valideringstallet (0,743). Valget mellom de beste modellene var i praksis tilfeldig. Bedre praksis hadde vært å bestemme *på forhånd* at modellvalget gjøres med kryssvalidering på trening + validering, og bare bruke testsettet til slutt. Da hadde trolig modellen med enkeltledd blitt valgt (ca. 0,02 bedre i CV).
- **Fiktive figurer ødelegger regresjonen.** De er 10 % av dataene, men står for en stor del av feilen i oppgave A. Fødselsårene deres (fra −10 000 til 10 190) er ikke en historisk epoke, og en modell som skal svare på «når levde personen?», burde kanskje ikke trenes på dem i det hele tatt.
- **Gamle personer predikeres for sent.** Med median over 400 års feil for antikken kan modellen bare grovt skille «gammel» fra «moderne». Det er få gamle personer i dataene, og MAE belønner å treffe den store moderne gruppen.
- **Den valgte modellen i oppgave A slår ikke baseline på medianfeil.** Random Forest minimerer kvadratfeil i hvert tre og blir dratt mot de ekstreme fødselsårene. SGD med absoluttfeil fikk omtrent samme medianfeil (106–109 år på validering), men dårligere MAE.
- **Sekkekategoriene i oppgave B** (`other`, `famous by association`) har ikke noe felles tema og blir aldri gode, uansett modell.

7 Hva ville vi gjort med mer tid?

1. **Modellvalg med kryssvalidering** på trening + validering, med usikkerhet (konfidensintervall) på alle tall, i stedet for ett valideringssett.

2. **Behandle ekte og fiktive personer separat** i oppgave A, for eksempel en klassifikator som først gjenkjenner fiktive figurer (del 1 viste at tekstene skiller dem godt), og en egen regresjonsmodell for ekte personer.
3. **Predikere epoke eller århundre som en klassifikasjonsoppgave**, slik at modellen ikke presses mot midten.
4. **Random Forest med absoluttfeil** (`criterion="absolute_error"`), som matcher MAE slik SGD-modellen gjorde, og trolig ville gitt bedre medianfeil. Den er mye tregere å trene.
5. **Bedre tekstrepresentasjoner:** setningsembeddinger (f.eks. fra en liten språkmodell) i stedet for TF-IDF. De forstår at *Principia* og *Newton* hører sammen.
6. **Hente ut data utenfra** (lov ifølge prosjektbeskrivelsen), for eksempel fødselsåret til favorittpersonen eller utgivelsesåret til favorittboka, som sterke variabler for oppgave A.
7. **Slå sammen eller modellere sekkekategoriene separat**, og analysere hvilke `occupation`-verdier som havner i `other`.

8 Konklusjon

Vi har undersøkt hva en språkmodell tror om 10 000 kjente personer og figurer, og om svarene den gir som dem, avslører når de levde og hva de drev med.

Del 1 viste at språkmodellen har et tydelig, men stereotypt bilde av historien. Kjente personer er omgjengelige, planmessige og reflekterte, oppgir IQ rundt 145 og vil heller ha et varig ettermæle enn et lykkelig liv. Personer fra før 1800 tror nesten sikkert på Gud og er autoritære, mens moderne personer er liberale, mer usikre på Gud og mer åpne for at vi lever i en simulering. Militære og politikere er autoritære, mens forfattere, filosofer og forskere er liberale og på venstresiden. Fiktive figurer skiller seg tydelig fra ekte, særlig i fritekstene.

Del 2 viste at svarene bærer mye informasjon. I **oppgave A** treffer Random Forest på alle svar fødselsåret med MAE på 285 år på testsettet (baseline: 452 år), men slår ikke baseline på medianfeil. Det viktigste svaret er hvilket *siste måltid* personen ville valgt. I **oppgave B** finner logistisk regresjon på alle svar riktig yrkeskategori med balanced accuracy 0,692 (baseline 0,10). Fritekstsvarene er den viktigste informasjonskilden i begge oppgavene, og feilene følger meningsfulle grenser mellom beslektede yrker og epoker.

Alt dette er mønstre i en bestemt språkmodell, ikke egenskaper ved de virkelige personene. Når modellene våre klarer å predikere epoke og yrke, er det fordi språkmodellen har sterke og systematiske assosiasjoner mellom tid, yrke, personlighet, verdier og smak.

9 Bruk av KI

Kunstig intelligens ble brukt i del 3 til å slå sammen og rydde opp notebookene fra del 1 og 2. KI ble også brukt til docstrings og korte kommentarer i koden, på del 1, 2 og 3. Alt innhold er gjennomgått og kontrollert mot resultatene i notebooken.